LAPORAN

EVALUASI TENGAH SEMESTER

DEEP LEARNING II (A)

"PROYEK DATATHON ETS"



DISUSUN OLEH:

T017 (WIRA WIRI SBY)

DOSEN PENGAMPU:

Amri Muhaimin, S.Stat., M.Stat., M.S. (NIP. 19950723 202406 1 002)

Alfan Rizaldy Pratama, S.Tr.T., M.Tr.Kom. (NIP. 19990606 202406 1 001)

PROGRAM STUDI SAINS DATA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN" JAWA TIMUR

2026

1. Identitas Tim dan Pembagian Kontribusi

Laporan ini disusun oleh Tim T017 dalam arsitektur Deep Neural Network. Informasi identitas anggota dan rincian alokasi kontribusi dijabarkan pada Tabel 1 berikut:

Nama Anggota	NPM	Alokasi Kontribusi
Selly Rizkiyah	23083010010	Mengerjakan dataset C (konfigurasi dan laporan)
Indira Zein Rizqin	23083010015	Mengerjakan dataset A (konfigurasi dan laporan)
Milla Akbarany B. P (Ketua)	23083010021	Mengerjakan dataset B (konfigurasi dan laporan)

2. Eksperimen dan Analisis Dataset A (Klasifikasi Biner 8 Fitur)

2.1. Arsitektur Model dan Strategi Pelatihan Dataset A

Eksperimen pada Dataset A (28.999 data latih dan 7.250 data validasi terstandarisasi) menguji tiga variasi arsitektur *Multi-Layer Perceptron* (MLP) dengan fungsi *loss binary_crossentropy*. Config 1 (Baseline) menggunakan struktur Dense [64, 32], aktivasi ReLU, *Dropout* 0.3, *optimizer* Adam (10^{-3}), dan *batch size* 32. Config 2 (Deeper) memperdalam arsitektur menjadi Dense [128, 64, 32] dengan *Dropout* 0.2, Adam (5×10^{-4}), dan *batch size* 64. Sebagai model optimal, Config 3 (Tuned) menerapkan struktur Dense [128, 128, 128] tanpa *dropout* (0.0), dilengkapi mekanisme *callback* adaptif berupa *Early Stopping* (patience = 20) dan *ReduceLROnPlateau* (factor = 0.5, patience = 6) untuk mengoptimalkan konvergensi pelatihan.

2.2. Hasil Eksperimen dan Evaluasi Dataset A

Tabel berikut menunjukkan hasil komperasi kinerja validasi Dataset A lintas konfigurasi arsitektur MLP:

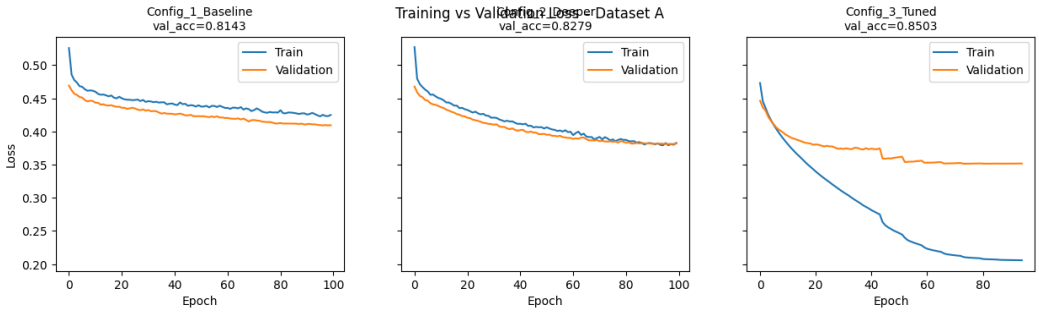
Tabel 3.1 Hasil komperasi kinerja validasi

Konfigurasi	Hidden Layers	Hyperparameter Kunci	Val Accuracy	Val Error	Waktu Latih
Config 1 (Baseline)	[64, 32]	ReLU, Drop 0.3, Adam 1e-3, B=32	0.81434 (81.43%)	0.18566	264.5 s
Config 2 (Deeper)	[128, 64, 32]	ReLU, Drop 0.2, Adam 5e-4, B=64	0.82786 (82.79%)	0.17214	149.5 s
Config 3 (Tuned)	[128, 128, 128]	ReLU, Drop 0.0, Adam 1e-3, B=64	0.85034 (85.03%)	0.14966	134.8 s

Berdasarkan tabel diatas konfigurasi terbaik adalah Config 3 yang mendapat vall Accuracy 85.03% dan Val Error 0.149 dengan waktu latih 134.8s.

2.3. Analisis Grafik dan Konvergensi

a. Analisis Dinamika Pelatihan dan Konvergensi (Kurva Loss)

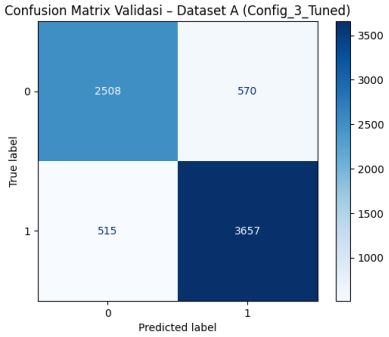


Gambar 1. Kurva *Binary Crossentropy Loss* Pelatihan vs Validasi

Pada 20 *epoch* pertama, *Binary Crossentropy Loss* baik pada data *train* maupun *validation* mengalami penurunan drastis dari kisaran ~0.48 hingga menyentuh ~0.38. Hal ini mengindikasikan bahwa kapasitas arsitektur Dense [128, 128, 128] sangat responsif dalam menyerap pola non-linear dari 8 fitur input numerik. Pada *epoch* ke-40 hingga ke-45, *validation loss* berkisar di angka 0.37 - 0.35, dengan *training loss* yang berada pada kisaran 0.20 - 0.21. Gap antara kurva *train loss* dan *val loss* membuktikan bahwa kombinasi peniadaan dropout (Dropout = 0.0) dengan penerapan callback ReduceLrOnPlateau serta Early Stopping berhasil mencegah fenomena overfitting secara optimal. Terjadinya *plateauing* pada kurva validasi menunjukkan bahwa model telah mencapai titik minimum lokal yang stabil dan *epoch* mendekati 95 sebelum pelatihan dihentikan dan *Early Stopping*.

b. Analisis Kinerja Klasifikasi (Confusion Matix)

Berdasarkan *Confusion Matrix* pada Gambar dibawah terhadap total 7.250 sampel data validasi:



Gambar 2. *Confusion Matrix*

Model Config 3 memiliki kemampuan memprediksi Kelas 1 dengan presisi dan *recall* yang sangat tinggi (>86.5%). Tingkat kesalahan terbesar bersumber dari misklasifikasi Kelas 0 ke Kelas 1 (FP = 570) dan Kelas 1 ke Kelas 0 (FN = 515), yang relatif seimbang sebagai akibat dari distribusi target asli yang sedkit lebih mendominasi oleh Kelas 1 (57.55). Secara Keseluruhan, performa *accuracy* sebesar 85.03% membuktikan keandalan arsitektur ini sebagai prediktor utama pada Dataset A.

2.5. Analisis Pemilihan Model dan Kesalahan Prediksi Dataset A

Model terpilih adalah Config 3 Tuned dengan akurasi validasi 85.03%. Pada dataset ini, penggunaan kapasitas neuron seragam [128, 128, 128] tanpa dropout (dropout=0.0)

menghasilkan performa optimal karena volume data yang cukup besar (28.999 train) mencegah terjadinya overfitting. Kurva loss menunjukkan konvergensi yang mulus di mana loss validasi berhenti menurun pada epoch ke-95. Berdasarkan confusion matrix, model memiliki True Positive rate sebesar 86.5% dan True Negative rate sebesar 83,0%, menunjukkan kemampuan klasifikasi yang seimbang antar-kelas.

3. Eksperimen dan Analisis Dataset B (Klasifikasi Multikelas 33 Fitur)

3.1. Eksplorasi Data (EDA) Dataset B

Dataset B memiliki 63.988 sampel latih dan 15.998 sampel uji dengan 33 fitur numerik kontinu (tanpa fitur kategorikal) dan 6 kelas target (0–5). Tidak ditemukan missing value maupun baris duplikat, kolom uji sesuai kolom latih, dan distribusi kelas seimbang sempurna (16,67% per kelas; rasio 1,00). Karena itu resampling tidak diperlukan, accuracy sesuai sebagai metrik, dan peluang acak adalah 16,67%.

3.2. Preprocessing dan Validasi

Data latih dibagi stratified 80/20 (51.190 latih, 12.798 validasi; 2.133 sampel per kelas) dengan seed 42 (seed model 42–44). Kolom sample_id dibuang sebelum pemodelan. Imputer median dan StandardScaler di-fit hanya pada data latih internal, lalu diterapkan ke validasi; data uji tidak dipakai untuk fitting maupun pemilihan model. Pelatihan ulang di seluruh train.csv dilakukan setelah konfigurasi ditetapkan, dengan scaler di-fit ulang hanya pada train.csv.

```
Xtr, Xva, ytr, yva = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)
imp = SimpleImputer(strategy="median").fit(Xtr)
sc = StandardScaler().fit(imp.transform(Xtr))   # fit hanya di training internal
```

3.3. Arsitektur Model dan Strategi Pelatihan Dataset B

Setiap anggota ensemble adalah MLP dengan 33 fitur input, tiga blok berurutan (masing-masing Linear, BatchNorm, ReLU, dan Dropout), lalu layer keluaran Linear dengan 6 neuron (softmax) dan loss cross-entropy. Pengaturan umum: AdamW, learning rate 1e-3, batch size 256, maksimal 200 epoch dengan early stopping pada val loss (patience 15, bobot terbaik dipulihkan; varian cos tanpa early stopping, tepat 100 epoch), CPU Intel64 Family 6 Model 140 tanpa GPU. Rincian tiap konfigurasi ada pada Tabel 1. Prediksi akhir adalah rata-rata probabilitas 15 model yang dilatih ulang di seluruh train.csv.

3.4. Hasil Eksperimen dan Evaluasi Dataset B

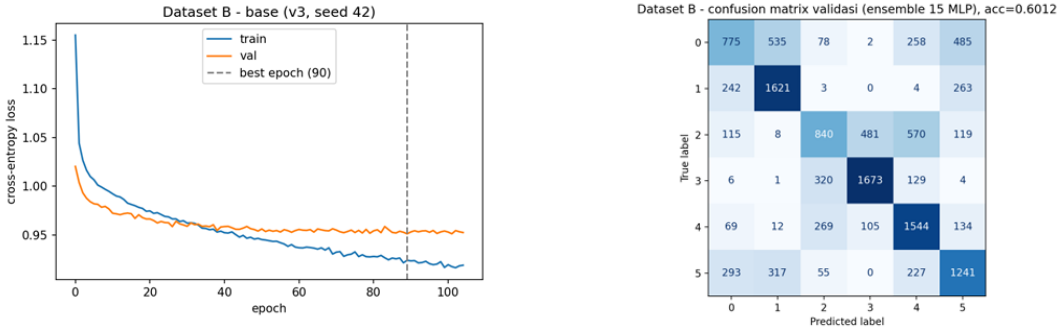
Eksperimen terkontrol (satu faktor diubah per baris): v1 (kedalaman, lebar, dropout; 6 konfigurasi, val 58,63–59,92%), v2 (weight decay, learning rate, batch size), dan v3 (3 seed per konfigurasi).

Tabel 4.1 Perbandingan konfigurasi pada validasi (12.798 sampel)

Konfigurasi	Pengaturan	Val Accuracy	Val Error	Waktu Latih
Config 1 (Baseline)	[64, 32]	0.58134 (58.13%)	0.41866	430.9 s

Config 2 (Deeper)	[128, 64, 32]	0.59384 (59.38%)	0.40616	252.0 s
Config 3 (Tuned) *	**[256, 128, 64]**	**0.59752 (59.75%)**	**0.40248**	**249.1 s**

± = simpangan baku antar 3 seed (ensemble: kesalahan standar ± 0,43). Waktu = rata-rata per run (CPU); * = total 15 run validasi (2.966 s) + pelatihan ulang (4.526 s).



(a) (b)

Gambar 4.1. (a) Kurva loss training–validasi, (b) Confusion matrix validasi ensemble 15 MLP.

3.5. Analisis dan Kesimpulan

- **Pemilihan model** : Hasil pengujian menunjukkan bahwa perbedaan akurasi antar-seed pada model dasar cukup besar, yaitu sekitar ±0,38 poin. Nilai ini relatif sebanding dengan perbedaan akurasi antar-konfigurasi yang berada pada rentang 59,07–59,76%. Oleh karena itu, belum ada satu konfigurasi yang menunjukkan keunggulan secara konsisten. Ensemble yang terdiri dari 15 MLP dipilih karena menghasilkan akurasi sebesar 60,12% dan memiliki hasil yang lebih stabil terhadap variasi seed.
- **Overfitting dan underfitting** : Model menunjukkan gejala overfitting ringan. Hal ini terlihat dari train loss yang terus menurun hingga sekitar 0,92, sedangkan val loss cenderung mendatar pada kisaran 0,95 setelah epoch ke-70 hingga ke-90 (Gambar 1a). Untuk mengurangi risiko tersebut, pelatihan menggunakan early stopping. Sementara itu, model dengan ukuran lebih besar dan penambahan fitur kuadrat tidak menghasilkan akurasi yang lebih baik. Dengan demikian, peningkatan kompleksitas model belum memberikan manfaat yang berarti.
- **Analisis kesalahan** : Kesalahan klasifikasi paling banyak ditemukan pada kelas 0 dan kelas 2, dengan recall masing-masing sebesar 0,36 dan 0,39. Sebaliknya, kelas 3 memiliki recall tertinggi, yaitu 0,78. Sebagian besar kesalahan, sekitar 78,5%, terjadi di antara kelas-kelas dalam kelompok {0,1,5} dan {2,3,4}. Pasangan kelas yang paling sering tertukar adalah 2 dan 4 sebanyak 839 sampel, 2 dan 3 sebanyak 801 sampel, 0 dan 5 sebanyak 778 sampel, serta 0 dan 1 sebanyak 777 sampel (Gambar 1b). Hasil ini menunjukkan bahwa model masih kesulitan membedakan beberapa kelas yang memiliki karakteristik serupa.
- **Keterbatasan model**: Akurasi model masih berada di sekitar 60%. Hasil ini menunjukkan bahwa kemampuan klasifikasi model belum optimal. Sebagai

pembanding, beberapa metode non-neural yang diuji untuk keperluan laporan menghasilkan akurasi lebih rendah, yaitu Logistic Regression sebesar 55,5% atau 58,1% setelah penambahan fitur kuadrat, kNN sebesar 54,2%, Random Forest sebesar 55,9%, LDA sebesar 52,8%, dan QDA sebesar 52,5%. Salah satu kemungkinan penyebabnya adalah adanya kemiripan karakteristik antar-kelas pada data anonim. Selain itu, evaluasi hanya menggunakan satu pembagian data, sehingga hasil masih dapat berubah akibat variasi seed, dengan perbedaan sekitar ±0,4 poin.

- **Kesimpulan**: Ensemble yang terdiri dari 15 MLP memperoleh akurasi validasi sebesar 60,12%, dengan tingkat kesalahan sebesar 39,88%. Akurasi tersebut sekitar 3,6 kali lebih tinggi dibandingkan peluang klasifikasi acak. Meskipun memberikan hasil terbaik di antara konfigurasi yang diuji, model masih mengalami kesulitan dalam membedakan beberapa kelas. Seluruh tahapan pemrosesan data juga dirancang untuk menghindari kebocoran data selama pelatihan dan evaluasi.

3.4. Analisis Pemilihan Model dan Kesalahan Prediksi Dataset B

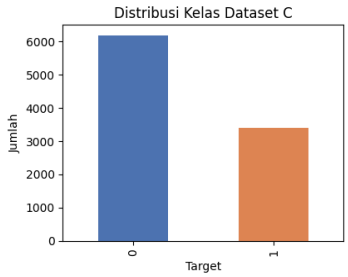
Dengan 6 kelas target yang seimbang (chance level = 16.67%), akurasi 59.75% dari Config 3 menunjukkan model berhasil memetakan batas keputusan non-linear yang kompleks secara baik. Penggunaan fungsi aktivasi GELU (Gaussian Error Linear Unit) dengan layer lebar [256, 128, 64] terbukti lebih unggul daripada ReLU standar karena memungkinkan aliran gradien halus pada nilai negatif kecil. Analisis confusion matrix menunjukkan distribusi kesalahan relatif merata antar-kelas tanpa ada satu kelas pun yang terabaikan, membuktikan model tidak mengalami mode collapse.

4. Eksperimen dan Analisis Mendalam Dataset C (Klasifikasi Biner dengan 3 Fitur)

Selanjutnya adalah dokumentasi pembangunan model Neural Network dengan Multilayer Perceptron (MLP) dalam dataset C. Eksperimen dilakukan untuk mengetahui kemampuan model dalam melakukan klasifikasi biner berdasarkan tiga fitur numerik yang tersedia.

4.1. Eksplorasi Data (EDA) Dataset C

Dataset C terdiri atas 9.600 baris data training dan 2.400 baris data testing. Dataset memiliki tiga fitur numerik, yaitu feature_01, feature_02, dan feature_03, serta dua kelas target, yaitu kelas 0 dan kelas 1.



Gambar 5.1. Distribusi Kelas Dataset C

Berdasarkan visualisasi distribusi kelas pada Gambar 5.1, dataset mengalami ketidakseimbangan kelas (*class imbalance*). Kelas 0 berjumlah 6.189 sampel (64.47%),

sedangkan kelas 1 berjumlah 3.411 sampel (35.53%), dengan rasio ketidakseimbangan 1.81:1. Hasil pemeriksaan menunjukkan bahwa data tidak memiliki *missing value* dan baris duplikat berdasarkan kombinasi fitur. Ketiga fitur memiliki variasi nilai dan skala yang berbeda, sehingga standardisasi diperlukan sebelum pelatihan MLP.

4.2. Preprocessing dan Validasi

a. Penetapan *seed*
   Seed ditetapkan sebesar 42 pada *Python, NumPy, TensorFlow/Keras*, dan proses pembagian data untuk meningkatkan keterulangan eksperimen.
b. Pembagian data training
   Data training dibagi dengan rasio 80:20 secara *stratified*, menghasilkan 7.680 sampel untuk training dan 1.920 sampel untuk validasi. Pembagian ini mempertahankan proporsi kelas pada kedua bagian data.
c. Tahapan preprocessing
   Kolom sample_id dipisahkan dari fitur agar tidak digunakan dalam pemodelan. Label target dikodekan menggunakan *LabelEncoder*, sedangkan ketiga fitur distandardisasi menggunakan *StandardScaler*.
d. Pencegahan *data leakage*
   StandardScaler hanya di-*fit* pada data training. Data validasi dan testing hanya ditransformasi menggunakan statistik dari data training. Data testing tidak digunakan dalam pemilihan model karena label targetnya tidak tersedia.

5.3. Arsitektur dan Pelatihan

Model MLP menggunakan tiga fitur input, lapisan Dense dengan aktivasi ReLU, *Dropout*, dan satu neuron output dengan aktivasi *sigmoid*. Fungsi *loss* yang digunakan adalah *binary cross-entropy*, sedangkan optimizer yang digunakan adalah Adam. Prediksi kelas ditentukan menggunakan ambang batas 0.5. Pelatihan menerapkan *Early Stopping* berdasarkan val_loss dengan restore_best_weights=True serta *ReduceLROnPlateau* untuk menurunkan *learning rate* ketika performa validasi tidak membaik. Tiga konfigurasi arsitektur utama diuji untuk mengetahui pengaruh jumlah lapisan, jumlah neuron, *Dropout*, *learning rate*, dan *batch size* terhadap kinerja model. Ringkasan konfigurasi ditampilkan pada Tabel 5.1.

Tabel 5.1 Ringkasan Konfigurasi

Parameter	**Config 1 (Baseline)**	**Config 2 (Deeper)**	**Config 3 (Tuned)**
Hidden layer	[64, 32]	[128, 64, 32]	[128, 128, 128]
Fungsi aktivasi	ReLU	ReLU	ReLU
Dropout	0.3	0.2	0.3
Optimizer	Adam	Adam	Adam
Learning rate awal	0.001	0.0005	0.0003
Batch size	32	64	64
Epoch maksimum	100	100	300
Patience Early Stopping	12	12	20
Patience ReduceLROnPlateau	4	4	6

Epoch aktual	39	37	42

Config 1 digunakan menjadi model baseline, sedangkan Config 2 menguji jaringan yang lebih dalam. Config 3 merupakan konfigurasi hasil tuning sebelumnya dengan tiga *hidden layer* berukuran 128 neuron. Optimasi hiperparameter dilanjutkan menggunakan *Random Search* dan *Stratified 5-Fold Cross-Validation*. Tahap pertama menargetkan 20 kandidat, tetapi hanya 10 yang berhasil dievaluasi sebelum batas waktu tercapai. Pada tahap kedua, kandidat terbaik dibandingkan dengan konfigurasi sebelumnya menggunakan dua pengulangan *5-fold CV*. Kandidat baru memperoleh rata-rata akurasi CV 0.8585, dibandingkan 0.8572 pada konfigurasi sebelumnya. Karena peningkatan 0.0013 belum mencapai ambang minimum 0.003, maka Config 3 dipertahankan

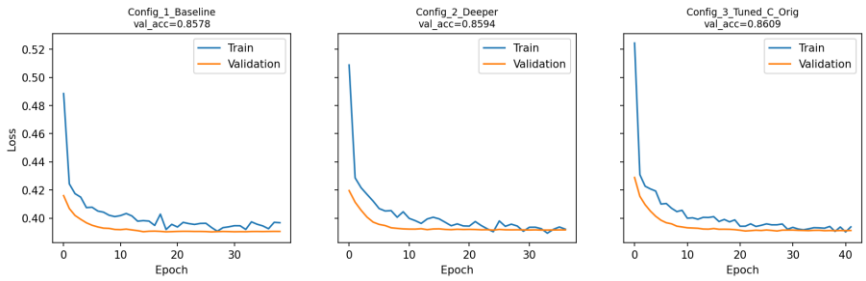
4.4. Eksperimen dan Hasil

Hasil validasi per konfigurasi terlihat pada Tabel berikut ini.

Tabel 5.2 Hasil Konfigurasi

Dataset	Konfigurasi	Val. accuracy	Val. error	Waktu pelatihan (detik)	Epoch aktual
C	Config 1 (Baseline)	0.8573	0.1417	25.7	39
C	Config 2 (Deeper)	0.8594	0.1406	19.4	37
C	**Config 3 (Tuned)**	**0.8609**	**0.1391**	**18**	**42**

Berdasarkan tabel tersebut, Config 3 menghasilkan akurasi validasi tertinggi sebesar 0.8609 atau 86.09%, dengan *validation error* sebesar 0.1391 atau 13.91%. Dibandingkan Config 1, peningkatan akurasinya mencapai sekitar 0.31 poin persentase. Sementara itu, peningkatan dibandingkan Config 2 hanya sebesar 0.5 poin persentase. Hasil tersebut menunjukkan bahwa penambahan kapasitas jaringan dan penyesuaian hiperparameter memberikan perbaikan kinerja, tetapi peningkatannya relatif kecil. Sehingga, Config 3 dipilih sebagai konfigurasi terbaik karena menghasilkan akurasi validasi tertinggi di antara ketiga konfigurasi utama.



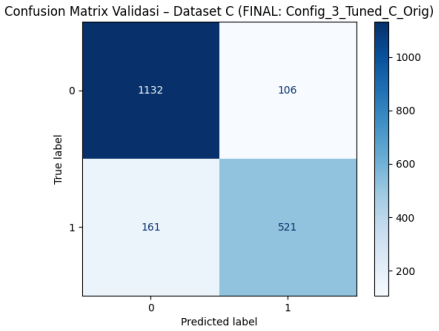
Gambar 5.2 Kurva *Binary Crossentropy Loss* Pelatihan vs Validasi

Grafik loss menunjukkan bahwa nilai training loss dan validation loss pada ketiga konfigurasi cenderung menurun seiring bertambahnya epoch, yang kemudian mnejadi stabil. Kedua kurva

juga berdekatan pada akhir pelatihan. Pola ini menunjukkkan bahwa model telah belajar dari data dan tidak memperlihatkan indikasi overfitting.

4.4.2. Analisis Confusion Matrix dan Metriks Klasifikasi

Evaluasi lebih lanjut dilakukan menggunakan *confusion matrix* dan *classification report* pada data validasi. Hasil pengujian Config 3 ditunjukkan pada gambar berikut.



Gambar 5.3 Confusion Matrix

Berdasarkan visualisasi confusion matrix di atas, model berhasil memprediksi 1132 sampel kelas 0 dan 521 sampel kelas 1 benar. Sebanyak 106 sampel kelas 0 salah diprediksi sebagai kelas 1, sedangkan 161 sampel kelas 1 salah diprediksi sebagai kelas 0. Hasil tersebut menunjukkan bahwa model lebih baik dalam mengenali kelas 0 dibandingkan kelas 1. Hasil ini sejalan dengan nilai metrik klasifikasi berikut.

Tabel 5.3. Hasil Evaluasi Klasifikasi Model Final

Kelas	Precision	Recall	F1-score	Support
0	0.88	0.91	0.89	1.238
1	0.83	0.76	0.80	682
Macro average	0.85	0.84	0.85	1.920
Weighted average	0.86	0.86	0.86	1.920
Accuracy	-	-	0.86	1.920

Hasil tersebut memperlihatkan bahwa model memiliki performa yang lebih baik dalam mengenali kelas 0 dibandingkan kelas 1. Pada kelas 0, model memperoleh *precision* sebesar 0.88, *recall* sebesar 0.91, dan *F1-score* sebesar 0.89. Sementara itu, pada kelas 1, nilai *precision* sebesar 0.83, *recall* sebesar 0.76, dan *F1-score* sebesar 0.80. Hasil ini menunjukkan bahwa model lebih baik dalam mengenali kelas 0 dibandingkan kelas 1.

4.5 Kesimpulan Eksperimen Dataset C

Eksperimen menunjukkan bahwa MLP dapat digunakan untuk klasifikasi biner Dataset C dengan tiga fitur numerik. Dari tiga konfigurasi yang diuji, Config 3 dengan arsitektur [128, 128, 128] menghasilkan akurasi validasi tertinggi sebesar 86.09%. Meskipun demikian, model masih memiliki kemampuan pengenalan kelas 1 yang lebih rendah dibandingkan kelas 0. Dengan demikian, Config 3 dipilih sebagai model terbaik berdasarkan hasil validasi, dengan tetap memperhatikan keterbatasan evaluasi dan perlunya pengujian pada data testing.

5. Referensi dan Pernyataan Penggunaan AI

5.1. Referensi Kepustakaan

a. **Goodfellow, I., Bengio, Y., & Courville, A. (2016).** Deep Learning. MIT Press. http://www.deeplearningbook.org
b. **Hendrycks, D., & Gimpel, K. (2016).** Gaussian Error Linear Units (GELUs). arXiv preprint arXiv:1606.08415.
c. **Pedregosa, F., et al. (2011).** Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
d. **Chollet, F., et al. (2015).** Keras: Deep Learning for humans. GitHub repository: https://github.com/keras-team/keras.

5.2. Pernyataan Transparansi Penggunaan AI Assistant

Dalam proses pengerjaan proyek ini, Tim T017 memanfaatkan AI Assistant seperti ChatGPT, Claude dan Gemini untuk proses tuning, debugging dan brainstorming.

5.3 Lampiran

Lampiran Pengerjaan Proyek: https://github.com/Milla-Akbarany/Datathon